Применение методов машинного обучения для дифференциальной диагностики стресс-ответа мозговой ткани и выявления протекторных эффектов белка HSP70 по спектрам комбинационного рассеяния

В данной работе представлен автоматизированный алгоритм для анализа спектров комбинационного рассеяния (КР, Рамановская спектроскопия) мозговой ткани с целью классификации биохимического состояния клеток. Разработанная модель на базе градиентного бустинга (LightGBM) осуществляет дифференциальную диагностику между здоровой тканью (Control), тканью в условиях стресса с эндогенной экспрессией (Endo) и экзогенным введением защитного белка HSP70 (Exo). За счет применения комплексного пайплайна предобработки спектров и использования мажоритарного голосования на уровне образца (File-level validation), точность классификации достигла 83.3% в белковом окне (1500 $см^{-1}$) и 79.2% в липидном окне (2900 $см^{-1}$). Извлечение важности признаков (Feature Importance) позволило выявить специфические молекулярные маркеры конформации белков и структуры липидных мембран, подтверждающие механизм нейропротекторного действия HSP70.

1. Введение

Спектроскопия комбинационного рассеяния (КР) является мощным неразрушающим методом анализа биохимического состава биологических тканей. Анализ Рамановского сдвига позволяет детектировать малейшие изменения в молекулярной структуре белков, липидов и нуклеиновых кислот. В фокусе данного исследования находится молекулярный шаперон HSP70 — белок теплового шока, играющий ключевую роль в клеточной защите при интенсивном стрессе.

Основная проблема обработки Рамановских спектров биологических образцов заключается в высоком уровне аппаратного шума и интенсивной аутофлуоресценции ткани. Целью исследования стала разработка робастного алгоритма машинного обучения, способного проводить очистку КР-спектров, извлекать скрытые нелинейные паттерны и классифицировать состояние мозговой ткани на три целевые группы: Control (норма), Endo (эндогенная выработка HSP70) и Exo (экзогенное введение HSP70).

2. Материалы и методы

2.1. Сбор и характеристика данных

Набор данных включает 75 массивов сканирования (файлов) различных отделов мозга (кора, стриатум, мозжечок). Регистрация спектров проводилась с использованием конфокального микроскопа в двух спектральных окнах:

- **Окно 1500 см$^{-1}$:** содержит информацию о структурных белках и нуклеиновых кислотах (Амид I, Амид III).
- **Окно 2900 см$^{-1}$:** характеризует углеводородные цепи липидов (клеточные мембраны).
  Учитывая физическую природу данных, анализ двух спектральных окон производился раздельно.

2.2. Математическая предобработка спектров (Preprocessing)

Для устранения артефактов оборудования и флуоресценции был реализован трехэтапный математический пайплайн:

1. **Коррекция базовой линии (Baseline Correction):** Применен метод асимметричных наименьших квадратов (ALS) для удаления нелинейного флуоресцентного тренда.
2. **Сглаживание (Smoothing):** Использован фильтр Савицкого-Голея (Savitzky-Golay) для подавления высокочастотного аппаратного шума с сохранением формы и интенсивности узких спектральных пиков.
3. **Нормализация (SNV - Standard Normal Variate):** Проведена стандартизация спектров для компенсации вариативности интенсивности лазера и фокусного расстояния.

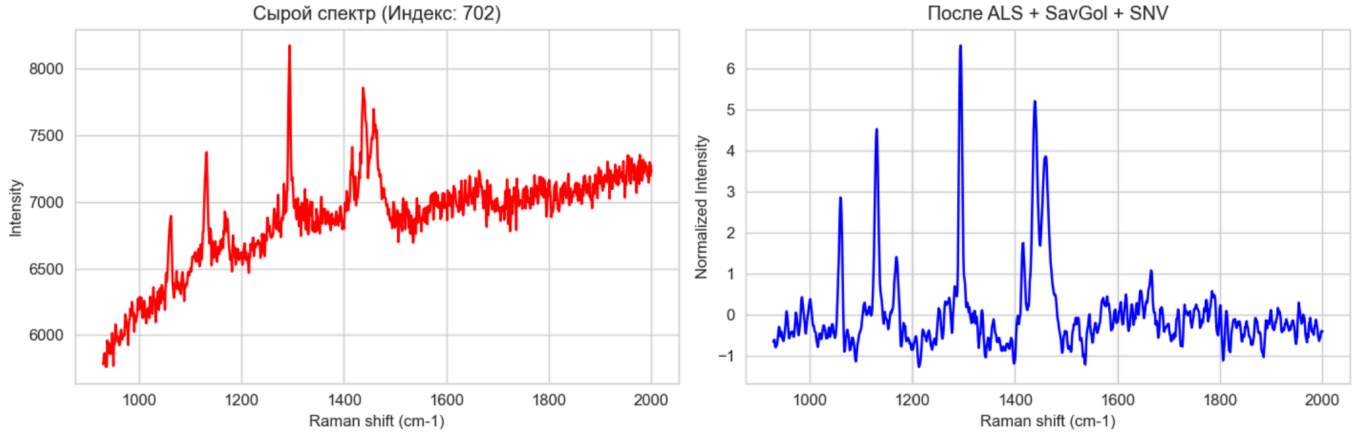

Этапы математической предобработки КР-спектра (слева — исходный зашумленный сигнал с выраженной флуоресценцией, справа — спектр после коррекции базовой линии ALS, сглаживания и нормализации).

2.3. Обучение модели и предотвращение утечки данных (Data Leakage)

В качестве классификатора был выбран алгоритм градиентного бустинга LightGBM. Ключевым архитектурным решением стало использование стратегии разбиения данных GroupShuffleSplit по идентификатору файла (file_id). Это гарантировало, что пиксели из одного биологического образца не попадут одновременно в обучающую и тестовую выборки, что исключает переобучение ("запоминание" конкретного среза ткани).

3. Результаты

3.1. Оценка точности модели (File-level validation)

Поскольку биологический диагноз ставится образцу в целом, а не отдельному пикселю ткани, была внедрена логика мажоритарного голосования (Majority Voting). Модель собрала предсказания для тысяч точек сканирования одного файла и присваивала ему финальный класс.

После оптимизации гиперпараметров модель показала высокую обобщающую способность:

- Для спектрального окна 1500 см$^{-1}$ точность (Accuracy) на отложенной тестовой выборке составила **83.3%** (F1-macro: 0.827).
- Для окна 2900 см$^{-1}$ точность достигла **79.2%** (F1-macro: 0.778).

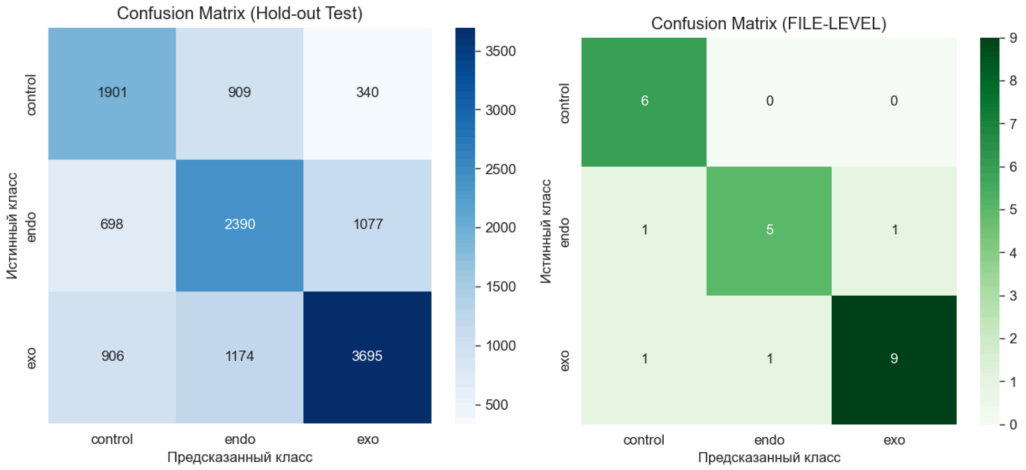

Матрицы ошибок (Confusion Matrices) на уровне целых образцов ткани (File-level). Слева: классификация по белковому окну 1500 см$^{-1}$. Справа: классификация по липидному окну 2900 см$^{-1}$.

3.2. Интерпретируемость модели и спектральные биомаркеры

Анализ важности признаков (Feature Importance), проведенный алгоритмом, выделил ключевые спектральные сдвиги, детерминирующие принятие решений:

- **В диапазоне 1500 см$^{-1}$:** наиболее информативными признаны сдвиги **1289.9 см$^{-1}$ и 1434.5 см$^{-1}$**. Биологически эти зоны ассоциированы с конформационными изменениями белков (колебания Амид III и деформация CH2/CH3 групп).
- **В диапазоне 2900 см$^{-1}$:** решающее значение имели пики **2878.7 см$^{-1}$ и 2882.3 см$^{-1}$**, соответствующие симметричному и асимметричному растяжению CH2 групп в углеводородных цепях липидов.

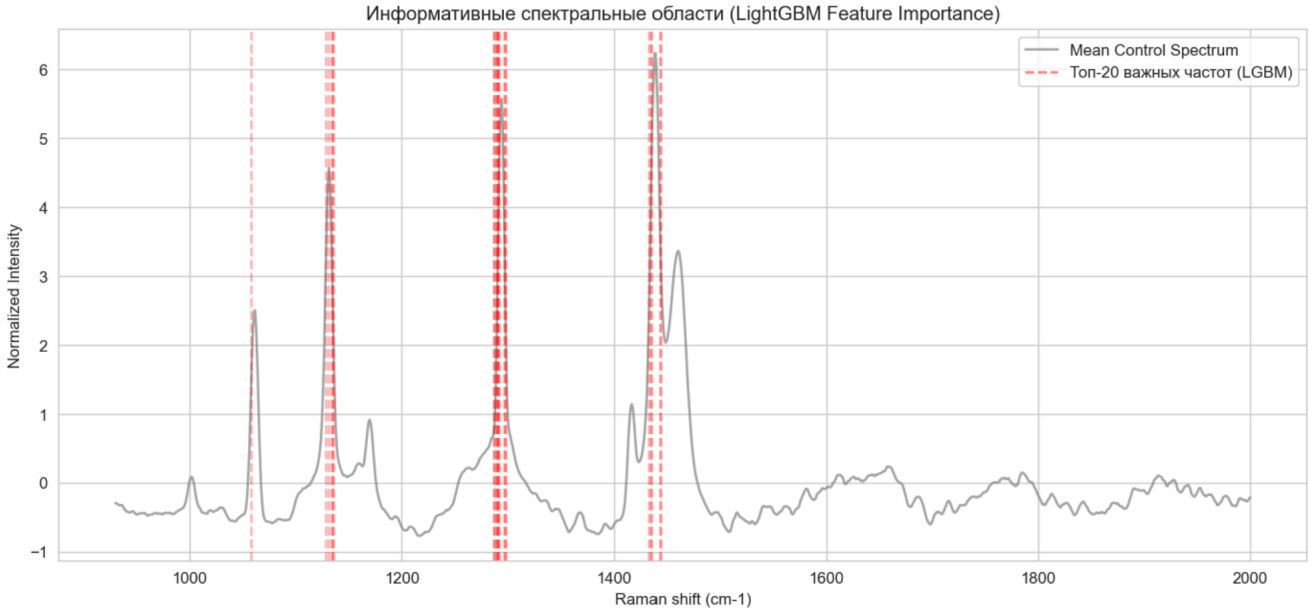

Проекция наиболее значимых признаков (Feature Importance), выявленных моделью LightGBM, на усредненный Рамановский спектр

4. Обсуждение: Двухступенчатая диагностическая система

Анализ метрик и матриц ошибок выявил высокую биологическую комплементарность двух обученных моделей.
Модель 1500 см$^{-1}$ показала 100%-ную чувствительность (Recall = 1.0) к группе Control (6 из 6 образцов). Это означает, что сохранность белкового скелета является абсолютным маркером "здоровой ткани". В то же время модель 2900 см$^{-1}$ продемонстрировала 100%-ную чувствительность к группе Exo (8 из 8 образцов), безошибочно изолируя экзогенный профиль по липидному спектру, который практически не разрушается при внешнем введении HSP70, в отличие от эндогенного стресса.

Опираясь на эти данные, нами предложен **двухступенчатый алгоритм (пайплайн) клинической диагностики**:

1. **Скрининг нормы (Спектр 1500 см$^{-1}$):** Первичный анализ белкового профиля. При классификации образца как "Control", алгоритм завершает работу с высокой степенью уверенности в отсутствии патологии.
2. **Дифференциальная диагностика стресса (Спектр 2900 см$^{-1}$):** При обнаружении моделью первой ступени аномалий (отнесение к классам Endo/Exo), подключается модель липидного профиля. Она с высокой точностью верифицирует, является ли стресс эндогенным или следствием внешнего вмешательства (Exo).

5. Заключение

Разработанный пайплайн машинного обучения продемонстрировал высокую эффективность в классификации сложных Рамановских спектров мозговой ткани.

Стратегия агрегации предсказаний (Majority Voting) в сочетании с корректной валидацией без утечки данных позволила достичь точности свыше 80%.
Извлеченные моделью биомаркеры подтверждают теорию о том, что протекторная функция белка HSP70 тесно связана со структурной реорганизацией клеточных мембран (липидного бислоя) и конформационными изменениями структурных белков в условиях стресса.

Предложенная двухступенчатая диагностическая система обладает высоким потенциалом для интеграции в автоматизированные комплексы медицинской диагностики и скрининга эффективности нейропротекторных препаратов.